

UTFPR – Universidade Tecnológica Federal do Paraná – Câmpus Cornélio
Procópio
Engenharia de Computação
Disciplina: Oficina de Integração

Processamento de Sinais Biológicos para Detectar o Movimento das Mãos.

Ana Livia Franco, Bruna Osti, Lucas Dolce, Matheus Nishikawa, Henrique Kim
{analivia@live.com,brunaosti@alunos.utfpr.edu.br,
lucasdolce11@gmail.com, matheusmnishi@gmail.com, henriquekm96@gmail.com}

19 de setembro de 2019

Sumário

1	Introdução	3
1.1	Justificativa	3
1.2	Objetivos	3
1.2.1	Objetivos Gerais	3
1.2.2	Etapas do Processo	4
2	Pesquisa de Mercado	4
2.1	Tendência de Mercado	5
3	Materiais e métodos	6
3.1	Implementação	6
3.2	Conjunto de dados	6
4	Condicionamento dos dados	7
4.1	Pré processamento	7
4.1.1	Janelamento	8
4.1.2	Normalização	8
4.1.3	Separação da base de teste e treinamento	8
5	Processamento	9
5.1	Extração de características	9
5.2	Classificação	10

5.3	Prototipação	10
6	Resultados	11
6.1	Primeira Etapa	11
6.2	Segunda Etapa	12
7	Conclusões	13
8	Trabalhos Futuros	13

1 Introdução

Portadores de deficiência motora são classificados como indivíduos que apresentam algum tipo de deficiência permanente, de grau superior ou igual a 60% de mobilidade, podendo ser de caráter evolutivo ou estável, sendo ocasionada por causas distintas, como acidentes ou doenças específicas. A deficiência resulta em dificuldades na locomoção e na realização de tarefas do dia-a-dia, sendo um fator limitante que pode impedir o indivíduo de realizar atividades simples em um contexto social [5].

Segundo o Censo do IBGE realizado em 2010 [5], aproximadamente 8,8 milhões de brasileiros apresentam algum tipo de deficiência motora, onde mais de 3,5 milhões têm sua deficiência classificada como alta, de modo que seu cotidiano seja totalmente afetado. Neste sentido, associações tecnológicas entre a engenharia e a medicina, como robótica assistiva, são responsáveis por projetar e desenvolver ferramentas capazes de auxiliar deficientes motores a melhorar sua qualidade de vida [1].

De acordo com pesquisas, os amputados são capazes de gerar sinais elétricos, a partir de células musculares, similares aos gerados por pessoas saudáveis. Devido esse fato, sinais de eletromiografia (EMG) podem ser utilizados para o desenvolvimento de equipamentos que recuperem parcialmente ou totalmente os movimentos motores perdidos[5].

A eletromiografia se trata do estudo da função muscular através da aquisição de sinais elétricos emanados pelos músculos. Os sinais de eletromiografia são gerados a partir de uma contração muscular que é realizada devido à disseminação de um determinado potencial de ação gerado pelos neurônios e células musculares. Essa atividade representa as propriedades fisiológicas e anatômicas dos músculos, onde a interpretação dessas características é realizada normalmente através do reconhecimento de padrões.

Baseando-se no cenário citado, o presente trabalho propõe o estudo e análise de sinais de eletromiografia utilizando ferramentas de aprendizado de máquina.

1.1 Justificativa

O registro da atividade eletromiográfica, permite a investigação de quais músculos são utilizados em determinado movimento, o nível de ativação muscular durante a execução do movimento, a intensidade e duração da solicitação muscular. Alguns trabalhos, relatam que as EMGs, por ser um método não-invasivo e representar a intenção de movimento do indivíduo, torna-se uma boa ferramenta para se ter o controle de uma prótese. Além de um processo interessante para ser tratado em meio acadêmico (diante de seu grande desafio, e não requisitado um grande investimento). Pesquisas levantam que o setor carece de atualização tecnológica, mesmo se tratando de um mercado extremamente lucrativo a indústria brasileira não possui o devido incentivo à tecnologia, o que implica no pagamento de uma série de impostos por produtos importados que atendam a demanda.

1.2 Objetivos

O presente trabalho tem como objetivo apresentar as principais características do processamento de sinais biológicos, desde a aquisição destes sinais, passando pelos processos de: pré processamento, processamento, classificação e previsão dos sinais.

1.2.1 Objetivos Gerais

- Analisar o sinal das EMGs na avaliação do movimento da musculatura do braço, para a captação e reconhecimento dos movimentos;
- Análise eletromiográfica, também em pessoas não amputadas, para coleta de dados e análise discreta;
- Análise do tipo do Sinal (padrões, período, etc.);
- Classificação do Movimento para futura replicação.

1.2.2 Etapas do Processo

- Pesquisa para averiguação, no caso, se as EMGs tem algum padrão no sinal de cada movimento;
- Projeção do circuito capaz de realizar o levantamento de dados;
- Pré Processamento do sinal(janelamento, estruturação, entre outros);
- Processamento do sinal utilizando Redes CNN.
- Classificar o movimento.
- Analisar a saída do processamento.

2 Pesquisa de Mercado

Segundo a Organização Mundial da Saúde (OMS) apenas 6.8% do orçamento público do governo federal era destinado para o setor da Saúde em 2014 [2], sendo bem abaixo da média mundial, que é de 11,7%, sendo este o último ano que estava disponível pela contabilidade da OMS, este valor se refere a taxa de 8,3 % do Produto Interno Bruto (PIB).

Atualmente são destinados 2% da arrecadação da receita para pesquisa e desenvolvimento tecnológico, valor significativo quando comparado com o investimento dado a outros setores(BNDES,2012). Estima-se que 23,9% da população possuía algum tipo de deficiência, segundo o censo do IBGE realizado em 2010.

As próteses representam cerca de 6,5% da indústria, e atendem os pacientes com deficiência motora; dentro dessa população 8,3% das pessoas apresentam deficiência severa, ou seja, tem perda total da sua capacidade, como mostra a figura 1.




Figura 1: Comparativo de deficiência de graus variados e deficiência severa
Fonte: IBGE(2010)

A deficiência severa se subdivide em classificações por tipo de deficiência apresentada, conforme a figura 2 mostra, vale ressaltar que os amputados são caracterizados como perda severa, pois perderam toda a sua capacidade motora.

Segundo o Censo do IBGE realizado em 2010 [3], 41,3% dos homens portadores de deficiência motora estão ativos no mercado, sendo apenas 27,4% para as mulheres, o resultado mostra que há um número elevado de deficientes que não se encontram ativos e uma das causas pode ser a ausência de próteses para melhorar o deslocamento dos mesmos, ou melhorar atividades que necessitam de movimentação ou interagir com o ambiente ao seu redor, como por exemplo: se alimentar, escovar os dentes, escrever e realizar expressões gestuais com a mão.

Nesse sentido, o uso de próteses cresceria proporcionalmente à incidência de casos de deficiência e aumentaria a quantidade de deficientes ativos no mercado.




Figura 2: Tipos de deficiência severa no Brasil
 Fonte: IBGE(2010)

O desenvolvimento de modelos inovadores de próteses proporcionará esperança aos portadores de deficiência motora, que tem a autoestima abalada pela condição física e garantirá uma melhor qualidade de vida. Por outro lado, o país aumentará a competitividade com produtos importados e também ganhará um aumento da mão de obra ativa.

2.1 Tendência de Mercado

A gestão de OPME (órteses, próteses e materiais especiais) traz muito desafios para os administradores, uma vez que grande parte do processo ainda se encontra nas mãos de terceiros, o que transforma o panorama nacional em uma situação que carece de atualização; É um mercado lucrativo para alguns, em detrimento das altas despesas para outros. O mercado de órteses e próteses movimenta cerca de R\$ 12 bilhões anualmente, um custo bastante complicado de administrar, seja pelo governo (por meio da saúde pública), seja pela rede privada de hospitais.

Um dos grandes entraves para o mercado de órteses e próteses está na carga tributária: como grande parte dos produtos é de origem importada, uma cadeia de tributos incide sobre os produtos aumentando em demasia seu preço final.

Portanto, é um mercado com bastante oportunidades de crescimento no Brasil visto que há poucas opções para os clientes e os custos são muito elevados pela maioria dos produtos serem importados, tirando o poder de escolha do cliente.

3 Materiais e métodos

Neste tópico será discutido as tecnologias que foram utilizadas para implementação do projeto, tendo em vista tanto a parte de software quanto a parte de hardware, e entendendo um pouco sobre suas limitações. O sistema completo pode ser descrito através do diagrama da figura 3.

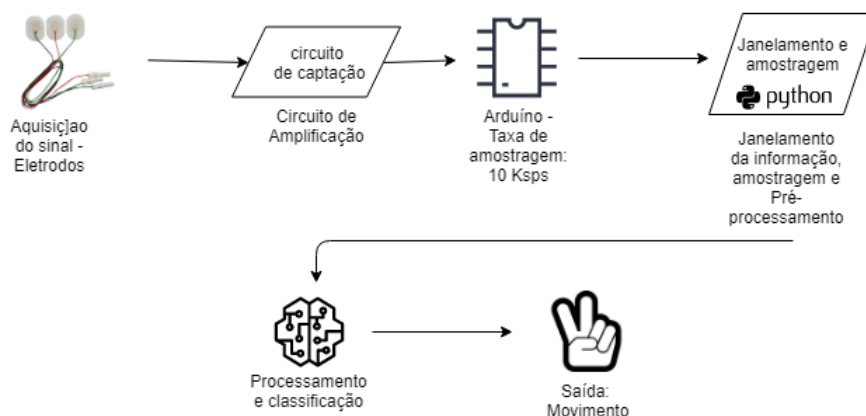


Figura 3: Diagrama do sistema

3.1 Implementação

Como linguagem de programação utilizou-se o Python pela sua capacidade de adaptação e pelo seu suporte a processamento de sinais e também o suporte a métodos de classificação que serão utilizados para caracterizar o movimento, como por exemplo as bibliotecas: *Scikit learn*, *Keras*.

Por outro lado, a parte de extração de dados em tempo real é feita através da conexão do software Arduino com o Python por meio de comunicação serial, a extração de dados em tempo real não interfere no código previamente implementado, apenas no pré-processamento do sinal.

A parte de processamento dos dados é toda implementada utilizando a biblioteca Keras, que fornece modelos de rede cnn e também métricas de desempenho.

3.2 Conjunto de dados

Utilizou-se o conjunto de dados disponível em [4], os dados não estão pré processados, ou seja, estão do mesmo jeito que o sensor captou primeiramente como mostra a figura 4(b), sendo classificadas como a figura 4(a): mão aberta, aceno, mão fechada, palma para baixo, palma para cima.

Em um segundo momento, a extração dos dados é feita em tempo real, estando disponíveis três classes: mão aberta, dedos, e mão fechada. A quantidade de classes diminuiu devido a complexidade da requisição de dados em tempo real.

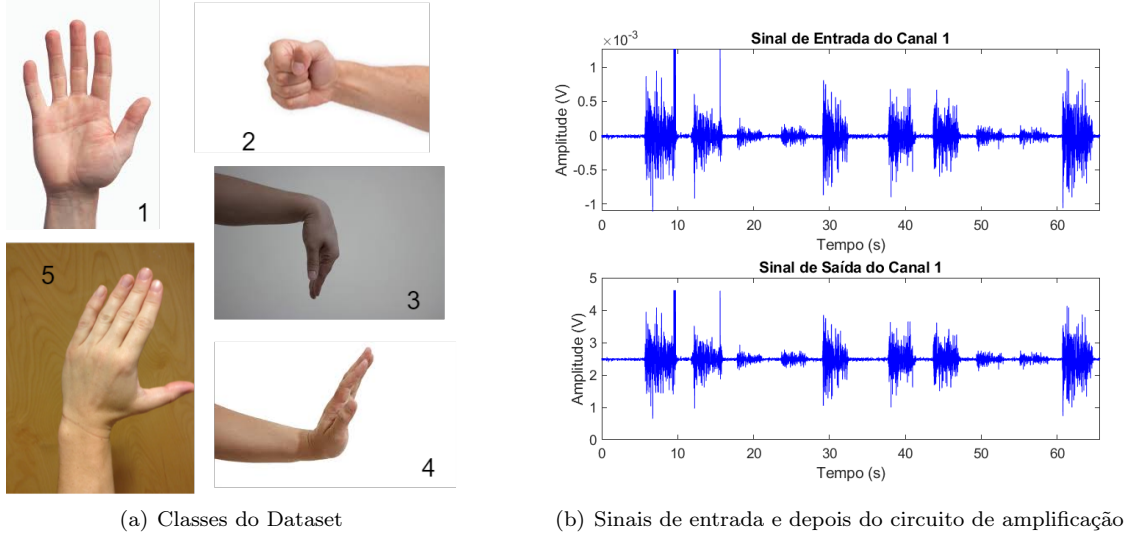


Figura 4: Conjunto de Dados

4 Condicionamento dos dados

Utilizou-se as duas configurações de amplificadores operacionais diretamente no Simulink. Como na figura , a primeira configuração é de um amplificador operacional inversor para que o sinal seja amplificado, onde podemos obter o valor de saída através da equação 1. Em seguida, ligado à saída do amplificador operacional (Amp. Op.) inversor temos outro amplificador operacional somador inversor, entretanto, a função desse amp. op. é gerar um offset no sinal, para que o sinal se adéque a tensão de entrada do microcontrolador que está entre 0 e 5v, onde a tensão de saída pode ser obtida através da equação 2.

$$V_{out} = -\frac{R_2}{R_1} * V_{in} \quad (1)$$

$$V_{out} = -\left(\frac{R_5}{R_4} * V_2 + \frac{R_5}{R_3} * V_1\right) \quad (2)$$

Portanto, prototipamos um circuito simples que funcionaria como um regulador do sinal para a entrada do Arduino, como mostra a figura 5, onde:

- Ganho - Fornece um ganho ao sinal coletado para uma melhor leitura pelo microcontrolador;
- Somador - Fornecer um offset no sinal para que o microcontrolador seja capaz de fazer a leitura, visto que ele é capaz de ler tensões de 0 a 5V.

4.1 Pré processamento

O pré processamento é responsável pela estrutura e a conceitualização na qual aquela aquela informação é criada, sendo responsável por deixar os dados padronizados para algum método de análise, como por exemplo as redes neurais.

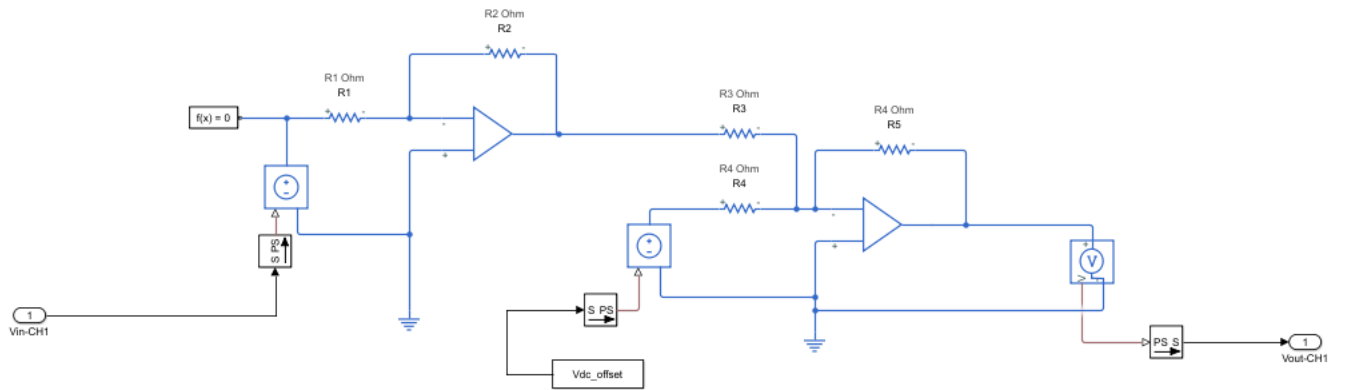


Figura 5: Circuito do Sistema

4.1.1 Janelamento

Utilizamos o janelamento pois o sinal que vem dos sensores é um sinal no tempo, ou seja, não apresenta período. Portanto, foi preciso a criação de uma janela de 500 amostras para cada um dos oito canais, para que o sinal tenha uma proporção/limite.

4.1.2 Normalização

Através da normalização é garantido que a base de dados tenha uma distribuição normal centrada em 0 e com os dados distribuídos apenas entre 0 e 1.

4.1.3 Separação da base de teste e treinamento

A partir dos dados janelados e normalizados, foi separado uma parcela deles para treinamento e para teste do modelo convolucional - A rede só teve acesso aos dados de treinamento, os dados de teste foram usados apenas para validar o modelo como mostra a figura 6.




Figura 6: Separação entre base de teste e treinamento no dataset de teste

5 Processamento

O processamento é responsável pela extração de características comuns a todos os sinais, portanto, é responsável por encontrar padrões entre um grupos de sinais, e assim ajustar os pesos sinápticos dos neurônios da rede.

5.1 Extração de características

As redes neurais convolucionais diferente dos métodos clássicos de classificação não necessitam de um especialista para extrair as características e informações do sinal. Isso traz como vantagem a simplicidade na elaboração dos modelos e também uma maior robustez visto que alguma característica importante pode não ser selecionada por um especialista enquanto no modelo convolucionais todas as principais características são selecionadas.

A estrutura convolucional para a classificação de movimento em uma prótese a partir do sinal de EMGs possui 10 camadas sendo elas divididas em três categorias, as camadas propriamente de convolução para encontrar os hiper parâmetros do sinal as camadas de pooling que extraem as características mais importantes do problema e por fim a camada de achatamento usado para alimentar o classificador, como mostra a figura 7.

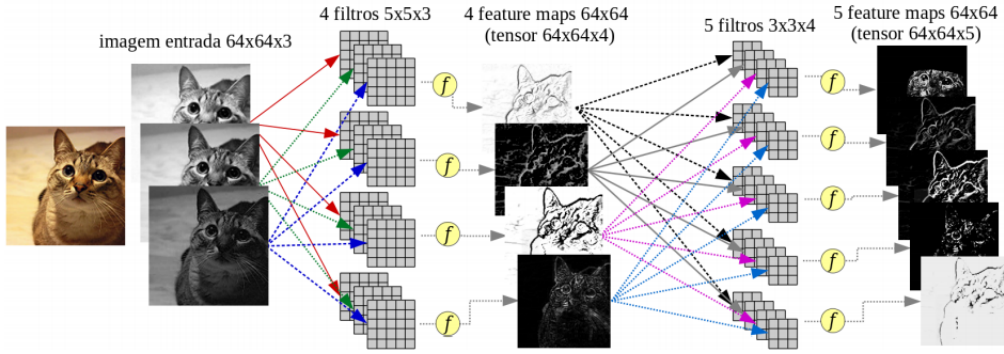


Figura 7: Funcionamento de uma rede neural convolucional

5.2 Classificação

Após a última camada da Rede Neural Convolucional existe uma camada de Classificação, com uma rede perceptron Multi Camadas como descrita na figura 8, onde no caso específico, utilizou-se 3 camadas. Na figura 8 está representado a estrutura básica de uma rede neural PMC, nela é possível observar que todos os neurônios estão conectados e o fluxo de informação é da entrada para a saída, o que dá a categoria desta rede *feedforward*.

O neurônio elemento que compõe a rede PMC tem as conexões de entrada ponderadas por um peso sináptico. Cada sinal de entrada X_i , é multiplicado pelo peso sináptico W_i . Por outro lado, o combinador linear é responsável pela soma dos valores de entrada ($x_1 * w_1 + \dots + x_n * w_n$), gerando o potencial de ativação. Entretanto, a função de ativação avalia o potencial de ativação U e através de uma função $g(u)$, calcula o sinal de saída do neurônio.




Figura 8: Classificador Perceptron Multi Camadas

5.3 Prototipação

Utilizou-se para a prototipação o sensor *ad8232* juntamente com eletrodos descartáveis como descrito na figura 9(a), sendo um sensor específico para eletrocardiograma, mas que tem o comportamento muito semelhante ao sensor de eletromiografia, a escolha desse sensor foi baseada em seu custo e sua disponibilidade no mercado. Além disso, para comunicação com a entrada serial do computador o módulo bluetooth *jymcu*, como técnica de diminuição de ruído.

De mesmo modo, utilizou-se o Arduino para o controle da frequência de amostragem e captura do sinal, como mostrado na figura 9(b). Entretanto, o sensor *ad8232* não foi confeccionado de forma integral como proposto

anteriormente devido a disponibilidade do amplificador operacional para sinais biológicos INA129 e a quantidade de ruído das primeiras tentativas, além de seu custo elevado.




Figura 9: Captura de dados

A formação da nova base de dados é feita por meio da integração da leitura do Arduino com o processamento do Python que gera uma lista de dados e é salvo em um arquivo csv, como na figura 10(b), onde é salvo o Tempo, a Tensão e o tipo de movimento(Classe), e optou-se pela coleta de três classes: Mão aberta, mão fechada e dedo do meio, pois apresentavam o sinal correspondente mais explícito no sinal captado.

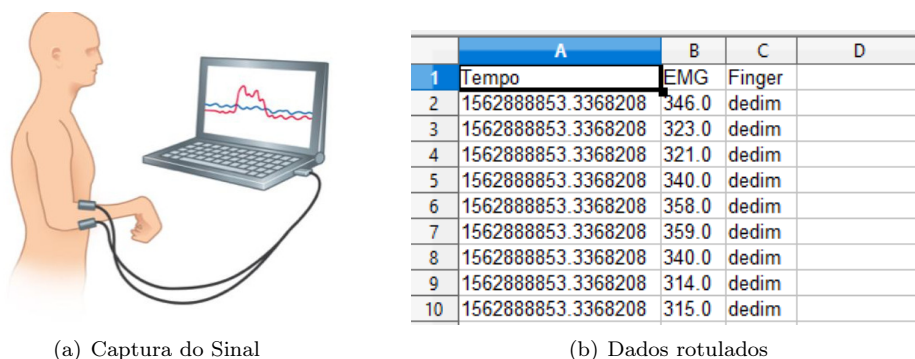


Figura 10: Captura da nova base de dados

6 Resultados

Nessa seção serão descritos os resultados da primeira etapa (apenas processamento do dataset), mas também os resultados provenientes da segunda etapa onde os dados a serem classificados são capturados em tempo real.

6.1 Primeira Etapa

A partir da rede convolucional descrita na seção anterior, treinou-se a rede com 50% dos dados, e salvou-se os pesos sinápticos em arquivos de formato h5, para que o carregamento desses pesos se torna-se otimizado. Em outro arquivo os pesos sinápticos salvo bem como os demais dados foram carregados para validar a topologia de classificação proposta.

A figura 11(a) apresenta a matriz de confusão para o resultado final da classificação, nela é possível observar que o classificador proposto foi capaz de classificar todas as classes de movimento com 100% de acurácia, visto

que todos os resultados se encontram na diagonal principal da matriz.

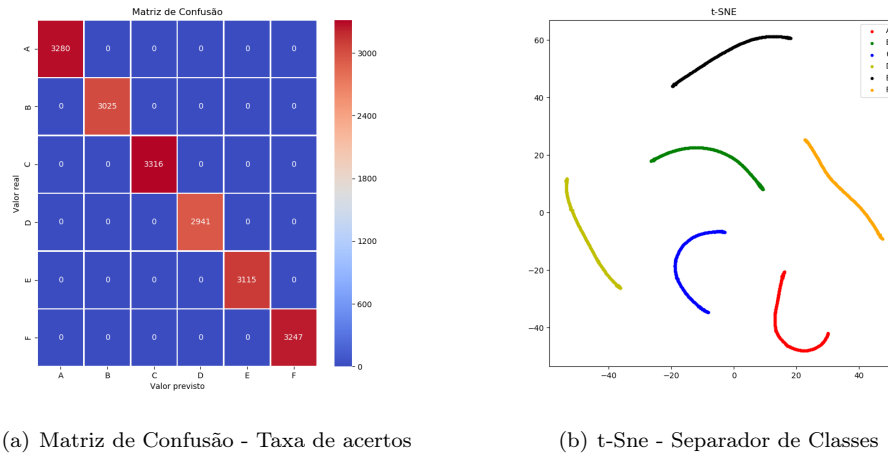


Figura 11: Resultados preliminares - Base de dados fixa

A figura 11(b) apresenta o t-sne para as características extraída pelas camadas convolucionais, o algoritmo de t-sne por meio de uma razão de probabilidades, cria uma representação bidimensional de um espaço multidimensional, possibilitando a visualização das regiões de separação entre as classes, o que é observado na figura 11(b) onde cada classe está agrupada em uma região com um espaço de separação entre elas.


6.2 Segunda Etapa

De mesmo modo, treinou-se a rede com 66% dos dados que foram previamente coletados e salvou-se os pesos sinápticos em arquivos de formato h5, para que o carregamento desses pesos se torna-se otimizado. Por outro lado, para que a arquitetura pré-treinada reconhecesse os dados em tempo real foi necessário que os dados fossem mandados em pequenos pacotes chamados de "batch" que é o janelamento em tempo real do sinal como é mostrado na figura 12.




Figura 12: Sinal Muscular em Tempo Real

A partir do batch enviado em tempo real, o modelo já pré-treinado consegue classificar com 80% de precisão o movimento, isso poderia ser melhorado através de filtros digitais ou até mesmo adicionando um circuito de desacoplamento do sinal eletromagnético.



(a) Teste em tempo Real



(b) Saída do Classificador no Terminal

Figura 13: Resultados finais - Tempo Real

O protótipo pode ser visto na figura 13(a)apresentou bons resultados, apesar de apresentar um certo delay, o que é natural visto que o hardware apresenta ruídos e o tempo de envio dos dados interfere do mesmo modo, onde pode ser observado pela saída, exemplificada na figura 13(b).

7 Conclusões

Pela razão que quase 9 milhões de brasileiros apresentam algum tipo de deficiência motora e que 3,5 milhões deles possuem sua deficiência classificada como severa, a utilização de aprendizado de máquina usando redes neurais convolucionais para o auxílio do estudo da eletromiografia se torna relevante, pois, como foi visto neste documento, foi possível analisar os sinais gerados por músculos e classificá-los de forma não tão custosa computacionalmente.

Com o refinamento desses métodos é possível que o custo para utilização dessas tecnologias se torne menor, e o produto se torne mais atraente para uso da população.

Contudo, o nível de complexidade do projeto desafiou a todos a saírem da zona de conforto e buscarem conhecimentos de outras fontes, não só da universidade, por um bem maior, onde futuramente possa trazer um maior conforto para essas pessoas que perderam sua privacidade por causa da dificuldade de mobilidade e de movimento, e melhorar de certa forma suas limitações.

8 Trabalhos Futuros

Os conhecimentos obtidos através do desenvolvimento deste trabalho podem ser consideravelmente ampliados a partir da construção de uma mão robótica, de modo que o movimento captado pelos eletrodos possam ser reproduzidos fisicamente. Além disso, uma nova classe de movimentos pode ser implementada, para que o modelo consiga classificar uma gama maior de movimentos. Dessa forma, o usuário se tornará capaz de realizar movimentos dos quais está impossibilitado, dando-lhe maior autonomia em suas atividades cotidianas e melhorando, consequentemente, sua qualidade de vida.

Outro fator de importante desenvolvimento futuro é a adaptação de todo o protótipo físico para uma versão

portátil. Garantindo assim, que o usuário possa utilizá-lo com maior frequência e diferentes situações. Desse modo, a aplicação do projeto se torna mais eficaz, abrangendo os principais problemas do público alvo e proporcionando a estes uma melhor experiência durante a utilização.

Referências

- [1] IBGE(Senso Demográfico), *Sistema ibge de recuperaÇÃo automÁtica*, apr 2019. [3](#)
- [2] Estadão, *Orçamento para saúde no brasil fica abaixo da média mundial, diz oms*, apr 2019. [4](#)
- [3] INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA, *Resultados censo 2010*, apr 2019. [4](#)
- [4] S. Lobov, N. Krilova, V. Kastalskiy, I. and Kazantsev, and V. Makarov, *Latent factors limiting the performance of sEMG-interfaces*, *Sensors* **18** (2018), no. 4, 1122. [6](#)
- [5] C. A. SIMÕES, *Reabilitação de crianças com deficiência motora pelo sistema Único de saúde na bahia: Desafios e perspectivas*, Master's thesis, Universidade Católica do Salvador (UCSal), 2008. [3](#)